面单识别与匹配系统

使 用 说 明　v2.1.1

重 要 声 明

本系统不自带人工智能模型。识别能力完全来自使用者本机另行安装的 Ollama 服务，以及该服务上运行的 Qwen 视觉语言模型（默认 qwen3-vl:2b-instruct）。

因此：未安装 Ollama、或 Ollama 未运行、或未拉取所选模型时，程序仍可启动并使用信息库功能，但无法完成任何面单识别。

v2.1.1 起界面顶部可切换三种模型（2B / 4B / 8B），单张识别约 2~4 秒。4B 与 8B 需自行拉取，程序不会代为下载。

识别准确率、速度与字段完整度取决于所部署的模型本身。更换为更强的 Qwen 视觉模型通常可提升效果，具体以实测为准。

项目	内容
软件版本	2.1.1
运行方式	解压即用，无需安装 Python 或其它运行库
必需外部依赖	Ollama 服务 ＋Qwen 视觉模型（qwen3-vl 系列）
文档用途	安装部署、界面操作、模型切换、命令行用法与故障处理

目　　录

章节	内容	页码
一	运行环境与依赖（Ollama 与 Qwen 模型安装）	2
二	安装与首次启动	3
三	界面与操作流程	4
四	信息库维护	6
五	命令行模式	7
六	常见问题	8
七	数据位置与备份	8

一、运行环境与依赖

项目	要求	说明
操作系统	Windows 10 / 11，64 位	本程序仅构建了 Windows 版本
程序本体	约 299 MB	解压后直接运行，无需安装
Ollama	必需，需保持运行	识别时的全部推理由此服务完成
Qwen 视觉模型	必需，约 1.8 GB	默认 qwen3-vl:2b-instruct
可选模型	4B / 8B，需自行拉取	界面下拉切换，或命令行 --model 指定
磁盘空间	程序 299 MB + 模型 1.8 GB 起	4B/8B 模型体积更大
内存	建议 8 GB 以上	默认模型参数量约 2.1B
网络	仅首次拉取模型需要	模型下载后可完全离线使用

1.1 依赖关系说明

本程序只负责三件事：界面呈现、字段比对与数据存储。「看图识字」这一步不在程序内完成，而是把图片交给本机的 Ollama 服务，由后者加载 Qwen 视觉模型推理后返回结构化字段。

程序通过 HTTP 访问 http://localhost:11434 与 Ollama 通信。图片与识别结果均不离开本机，不经过任何外部服务器。

换言之：程序是「客户端」，Ollama 是「服务端」，Qwen 模型是「能力本身」。三者缺一不可。

1.2 安装 Ollama

1. 从 ollama.com 下载 Windows 安装包并完成安装。
2. 安装完成后 Ollama 会自动启动并常驻系统托盘，无需手动开启。
3. 验证：打开 PowerShell 执行下列命令，能输出版本号即为正常。

```
ollama --version
```

1.3 拉取 Qwen 视觉模型

模型不会随程序分发，必须另行下载一次（约 1.8 GB）：

```
ollama pull qwen3-vl:2b-instruct
```

如需使用 4B / 8B（可选，体积与显存占用更大）：

```
ollama pull qwen3-vl:4b-instruct-q4_k_m
ollama pull qwen3-vl:8b-instruct-q4_k_m
```

下载完成后确认模型已在本地：

```
ollama list
```

列表中应出现所拉取的模型。注意必须是 qwen3-vl 这类视觉多模态模型；若换成纯文本模型（如 qwen2.5、llama3 等）无法读取图片。

二、安装与首次启动

2.1 解压与启动

1. 将分发包解压到任意目录（路径中建议不含空格以外的特殊字符）。
2. 双击目录中的 ParcelDetective.exe 启动程序。
3. 程序首次启动会自动初始化信息库，无需手工建库。

2.2 首次自检（建议执行）

在程序目录打开 PowerShell，执行：

```
.\ParcelDetective.exe --ai-check
```

该命令只检查 Ollama 服务与模型是否就绪，不做识别，返回结果如下：

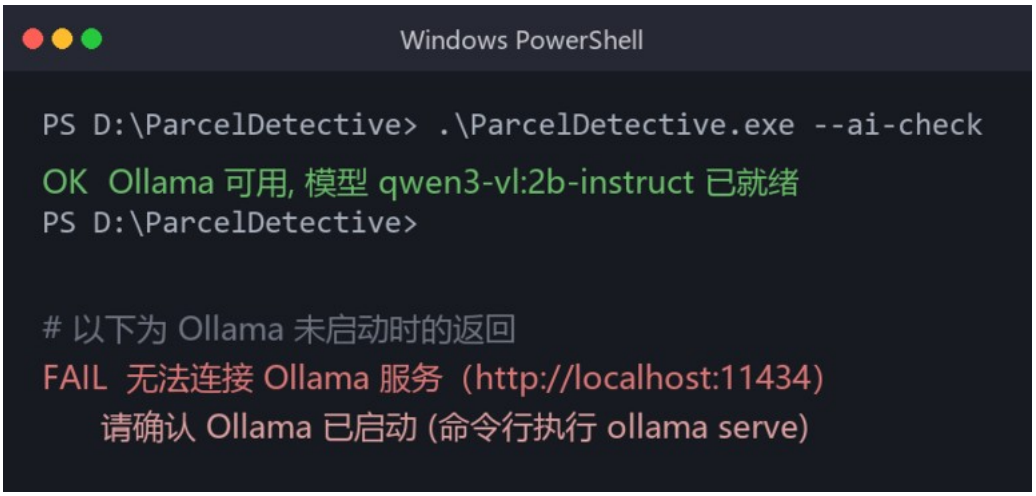


图 1　自检命令的实际输出（上为就绪，下为服务未启动）

看到 OK 即表示可以正常使用。若返回 FAIL，请按第六节处理后再使用。

2.3 选择识别模型（v2.1.0 新增）

程序顶部有一行「识别模型」，下拉框列出三种模型，默认 2B Instruct：

模型	定位	说明
qwen3-vl:2b-instruct	默认	约 1.8 GB，单张约 2~4 秒（模型已加载）
qwen3-vl:4b-instruct-q4_k_m	平衡	需自行拉取；显存与耗时高于 2B
qwen3-vl:8b-instruct-q4_k_m	精度优先	需自行拉取；最慢，适合疑难面单

切换后立即检查 Ollama 服务与该模型是否已安装（下拉框短暂禁用，通常不足 1 秒）。通过时显示绿色「已就绪」；失败时显示红色「不可用」并弹出「模型可用性异常报告」，写明原因与应执行的命令。报告只作提示，程序不会退出，可切回其它模型继续使用。

每次开始识别前会复查一次；所选模型不可用时取消本次识别并说明原因，避免空耗重试。模型选择不保存，重启回到默认 2B；可用环境变量 PARCEL_AI_MODEL 或命令行 --model 固定（见第五节）。

三、界面与操作流程

程序为双页签结构：「一键检测」用于识别与判定，「信息库」用于维护比对依据。



图 2　主界面「一键检测」页（顶部含「识别模型」一行）

3.1 单张检测

识别前先确认顶部「识别模型」为所需模型，其右侧显示「已就绪」即可开始；显示「不可用」时按 2.3 节处理。

首次识别需等模型加载（约 5~10 秒）；模型常驻后单张约 2~4 秒。若单张要几十秒，多半是模型没跑在 GPU 上，见第六节。

1. 点击上方蓝色按钮「上传图片并识别」，选择一张面单照片。
2. 等待识别完成。顶栏会显示进度阶段：正在启动 AI 视觉识别 → AI 识别完成，正在比对数据库 → 处理完成。
3. 查看「判定结论」区的结论、得分、单号、原因与处置建议。
4. 在「信息对照」页签逐项核对 AI 识别值与信息库值；不一致项会以颜色标出。
5. 「Top-3 匹配结果」列出最接近的记录，点选任意一行即可切换对照对象。
6. 确认无误后按建议处置；也可在信息库页将该条补录入库。

3.2 批量检测

在上传对话框中选择多张图片即可。批量过程中：

- 顶栏显示「第 N / M 张」，可用「上一张」「下一张」逐张复核。

- 切换图片时，图片对照与字段对照会同步更新。
- 勾选「通过时自动入库」可将判定为通过的记录直接写入信息库。
- 随时可点「停止」中止，已完成的结果保留。

3.3 判定结论的含义

结论	触发条件	处置建议
通过	加权得分 ≥ 0.85	可自动打单或直接放行
待确认	0.60 ≤ 得分 < 0.85	人工快速核对候选记录后放行
人工	得分 < 0.60，或未提取到有效字段	转人工处理，必要时补录信息库

3.4 寄件方与收件方对调

模型偶尔会把寄件方与收件方信息互换。若发现对照中两侧明显颠倒，点击「对调收/发件方」，程序会交换两侧字段并按同一套阈值重新判定。

3.5 图片对照的使用

左右两图分别对应「本次检测图」与「信息库记录图」，各自可独立旋转与复位，勾选「两侧同转」可保持角度一致；双击任一图片可用系统看图工具打开原图。

四、信息库维护

信息库是判定的依据来源；它的完整程度直接决定识别结果是否可用。

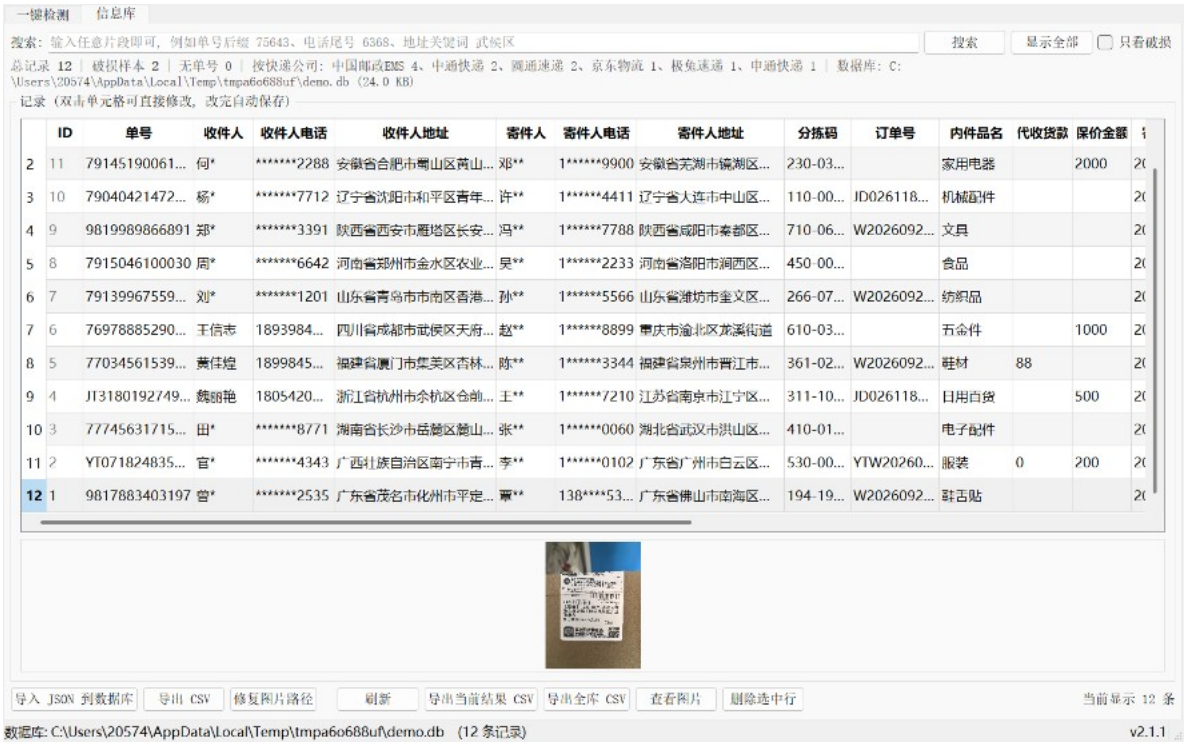


图 3 「信息库」页（示例数据）

操作	方法
新增记录	点击「新增」，或由检测结果通过「通过时自动入库」写入
修改记录	双击单元格直接编辑，改完自动保存
删除记录	选中行后点击「删除选中行」
检索	顶部搜索框支持单号后缀、电话尾号、地址关键词等任意片段
只看破损	勾选该选项可筛出已标记破损的样本
图片预览	选中记录即在下方面板显示面单原件
修复图片路径	图片被移动后，点击「修复图片路径」重新指向
导入 / 导出	支持 JSON 导入入库、CSV 导出全库或当前检索结果

五、命令行模式

除图形界面外，程序支持无界面批处理，便于与其它流程集成。

参数	作用
--ai 图片 [图片...]	对指定图片执行识别与判定
--ai-check [--model 模型]	仅检查 Ollama 服务与指定模型是否就绪
--models	列出三种可选模型及本机安装状态
--model 模型名	指定本次识别使用的模型（优先级最高）
--stats	打印信息库统计信息
--db 路径	指定数据库文件，默认使用用户数据目录下的库
--top N	显示前 N 个候选记录，默认 3
--save	判定为通过的记录自动入库
--out 文件.json	将完整结果写入 JSON 文件

示例：

```
.\ParcelDetective.exe --ai "D:\面单\a.jpg" --model qwen3-vl:4b-instruct-q4_k_m
.\ParcelDetective.exe --ai-check --model qwen3-vl:8b-instruct-q4_k_m
.\ParcelDetective.exe --models
```

退出码	含义
0	全部判定为「通过」；--ai-check / --models 表示就绪
1	存在「待确认」或「人工」；检查命令表示不可用
2	参数错误或运行错误

六、常见问题

现象	原因	处理
提示「AI 服务未运行，无法识别」	Ollama 未启动或已退出	开始菜单打开 Ollama，或命令行执行 ollama serve，确认托盘有图标后重试
提示「请先执行 ollama pull …」	本地缺少所选模型	执行 ollama pull <模型名>；默认模型为 qwen3-vl:2b-instruct
切到 4B/8B 后显示「不可用」，或提示「所选模型不可用，已取消本次识别」	该模型尚未拉取	先 ollama pull 对应模型，再点「检查」；也可切回 2B。--models 可查看安装状态
提示「模型没有返回任何内容」	模型输出格式异常或超时	程序已自动重试三档；仍失败可换更小的模型或稍后重试
单张耗时几十秒（不是 2~4 秒）	模型没跑在 GPU 上：显存不足或后端未选中	命令行执行 ollama ps：PROCESSOR 应为 100% GPU；若是 100% CPU，重启 Ollama，并确认没有把上下文调到 32768（8 GB 显存装不下）
每半小时后的第一张要等 5~10 秒	模型空闲超时后被卸载，重新加载	正常现象；连续作业时模型常驻，单张 2~4 秒
判定长期停留在「待确认」	信息库字段脱敏严重，加权分上不去	补全信息库中的电话、地址等字段
右侧提示「该记录在信息库里没有关联图片」	该条记录未存图片路径	在信息库页点「修复图片路径」补上
右侧提示「找不到图片文件」	图片被移动或删除	同上；或把图片放回原路径
命令行输出保存到文件后中文乱码	编码不一致	程序已按 UTF-8 写出，请以 UTF-8 打开该文件

七、数据位置与备份

项目	位置 / 说明
默认数据库	%LOCALAPPDATA%\ParcelDeskewOCR\parcels.db
便携模式	程序同级目录若存在 parcels.db，则优先使用该文件
自动备份	每次写入前自动备份，误操作可回退
卸载	直接删除程序目录即可；数据库需手动删除
模型选择	不随程序保存，重启回到默认 2B；可用 PARCEL_AI_MODEL 固定
迁移到另一台电脑	拷贝程序目录与 parcels.db；新电脑需另装 Ollama 并拉取所用模型

再次提示：关于外部依赖

程序的识别能力不来自程序本身。部署到新电脑时，除拷贝程序目录外，还必须在该电脑上安装 Ollama、拉取 Qwen 视觉模型，并确认服务处于运行状态。

若用环境变量或命令行固定了模型，新电脑必须存在同名模型，否则检查会失败。

可用 .\ParcelDetective.exe --ai-check --model 模型名 一条命令确认是否就绪。